需求规格说明书

海洋数据采集与处理项目

从多源科学数据到可复用主题数据的企业级离线处理闭环

文档编号	OI-DP-SRS-001
版本	V1.0
文档状态	初稿
编制日期	2026年8月21日
适用对象	项目干系人
系统边界	原始NC/NPZ/ZIP-CSV → DataX/HDFS/Hive/Spark → 云端MySQL/MariaDB ADS主题库

本文件基于数据资产审计结果编制，用于明确项目范围、功能、数据标准、质量要求、交付物和验收标准。

核心业务主线

以全球海洋多源原始数据为数据基础，面向西北太平洋轻量化实训范围构建海洋数据采集、治理、分析与可视化体系，分析温度、盐度、热含量、海流、溶解氧的时空变化，并探索区域海洋环境与渔船作业活动之间的关系。

文档控制

版本	日期	状态	说明
V1.0	2026-08-21	初稿	基于数据资产审计形成的首版需求说明

确认重点

两个项目的范围与上下游边界是否清晰；

轻量化数据范围是否满足4核8G单节点环境；

功能、指标、交付物与验收标准是否完整；

暂定项是否允许进入详细设计与性能验证阶段。

目录

01 文档概述

02 项目背景与目标

03 项目范围与边界
04 用户与使用场景
05 数据资产与审计结论
06 总体业务流程
07 技术架构与部署
08 功能需求
09 数据标准与数仓模型
10 轻量化数据方案
11 非功能需求
12 交付物与验收
13 风险与待确认事项
14 附录

1 文档概述

1.1 编制目的

本文件定义海洋数据采集与处理项目V1.0的业务目标、范围、数据规则、功能、非功能要求、交付物和验收标准，作为需求确认、详细设计、开发、测试和交付的共同依据。

1.2 需求基线

- 事实依据：项目原始数据集及《海洋数据资产审计结论V1.0》。
- 项目关系：本项目为项目二“海洋大数据可视化”提供标准化、可追溯、可查询的数据产品。
- 暂定运行环境：阿里云ECS，4核8GB、80GB最低/100GB推荐，单节点伪分布式。

1.3 术语

术语	定义
NetCDF/NC	海洋、气象领域常见的多维科学数据格式。
NPZ	NumPy压缩数组容器，本项目用于温度预测训练、目标和测试数组。
格点数据	按规则经纬度网格及深度层组织的海洋指标数据。
ODS/DWD/DWS/ADS	原始层、明细标准层、汇总服务层、应用数据层。
MMSI	船舶海上移动业务识别码；本项目与年份共同构成渔船主数据业务键。

2 项目背景与目标

项目拥有约21.05GB真实海洋数据，包括645个NC文件、2个NPZ文件、11个年度渔船ZIP及渔船主数据。渔船逐日数据全量为591,806,949条记录，数据格式异构、时间跨度不一致、空间网格不一致，并存在未自动识别的哨兵值，具备真实数据工程项目所需的复杂性。

2.1 建设目标

- 建立NC、NPZ、ZIP/CSV多源文件的可重复采集与解析能力。
- 建立时间、坐标、深度、单位、字段和缺失值统一的数据标准。
- 建立ODS、DWD、DWS、ADS四层离线数仓与可追溯处理链路。
- 利用Spark完成海洋格点、渔船明细的清洗、聚合和时空关联。
- 将ADS主题结果发布至ECS上的MySQL/MariaDB结果库，并同步导出CSV备用数据包，供FineBI通过数据库连接抽取使用。
- 确保轻量化运行方案可在4核8G服务器上稳定完成核心数据处理流程。

2.2 成功标准

> 项目成功 系统能够稳定完成环境验证、多源采集、清洗转换、数仓加工、主题表生成和质量核验；项目二能够稳定消费其ADS数据。

3 项目范围与边界

3.1 项目范围内

- Python解析NC和NPZ，流式读取年度渔船ZIP中的日CSV；
- Python解析、DataX采集、HDFS文件组织、Hive数仓分层、Spark清洗聚合及云端ADS结果库发布；
- 数据标准化、质量校验、处理日志、幂等运行和失败重跑；
- 轻量化运行数据包、代码、SQL、Shell脚本、数据字典和技术文档。

3.2 项目范围外

- 轻量化部署不直接处理21GB全量数据或5.92亿条渔船明细；
- 不在本项目的数据处理服务器上部署FineBI；
- 不建设实时流处理、Kafka、HBase、DolphinScheduler或Airflow；
- 不把缺少真实坐标和日期的预测NPZ强行关联至全球渔船数据；
- 不在本项目内完成最终FineBI页面和海洋综合可视化大屏。

3.3 与项目二的数据交付边界

交付项	项目一责任	项目二责任
数据	输出云端ADS主题表、备用CSV、数据字典、刷新时间和质量结果	从云端结果库抽取并建立FineBI数据模型
指标	实现可复用基础度量及聚合字段	定义展示口径、计算字段和交互
性能	保证主题查询源可用且规模受控	保证图表加载、筛选和联动性能
问题处理	修复源数据和加工逻辑问题	修复展示、模型和交互问题

4 用户与使用场景

角色	主要诉求	权限边界
项目负责人	确认范围、进度、质量和交付结果	查看全部项目资料与运行结果
数据工程师	开发、测试和维护完整数据流水线	数据处理环境受控管理权限
数据质量人员	配置质量规则并核验处理结果	数据与质量报告只读/审核权限
BI开发人员	使用ADS表构建项目二	主题库只读或受控访问

4.1 核心场景

1. 从一个月NC文件认识多维科学数据，并批量解析多个月份。
2. 流式读取ZIP而不全量解压，清洗并导入渔船逐日明细。
3. 将0—360经度转换为-180—180，统一时间、深度和网格。
4. 在Hive/Spark中生成月度海洋指标、渔船网格和关联主题数据。
5. 一键执行Shell流水线并依据质量报告判断结果是否合格。

5 数据资产与审计结论

5.1 数据资产

数据资产	格式	规模/记录	时间范围	用途
多参数格点数据	NC	645个，13.966GB	2011—2026，指标不一	环境指标主数据
温度预测数据	NPZ/CSV	2.214GB	无真实日期数组	独立预测专题
渔船逐日数据	ZIP/CSV	4,018个日文件，591,806,949条	2014—2024	作业行为分析
渔船主数据	CSV	773,165行，192,582个MMSI	2012—2024	船旗国、船型和规格

5.2 关键审计结论

- 五项指标共同月份为2016-01至2021-12，共72个月。

- 盐度999和热含量约1e30为未自动屏蔽的无效哨兵值。
- 温度/盐度/溶解氧、海流、热含量的经纬度中心和深度结构不同，不能直接等值连接。
- 海流由u、v分量构成，需要派生流速与流向。
- 渔船主表应按mmsi + year关联；日表经度为-180—180，NC为0—360。
- 预测NPZ缺真实日期、经纬度和深度值；示例提交文件与预测脚本形状不一致。

数据约束 预测数据暂作为独立专题；任何跨源指标必须基于共同时间、统一网格和可追溯口径，禁止以业务想象代替数据证据。

6 总体业务流程

阶段	输入	核心处理	输出
采集	NC、NPZ、ZIP/CSV	元数据登记、文件校验、流式读取	ODS文件与采集日志
解析	ODS源文件	多维展开、字段映射、格式转换	结构化明细
治理	结构化明细	去重、哨兵值、物理范围、坐标时间统一	DWD标准明细
汇总	DWD	月度、网格、深度、船旗国、船型聚合	DWS汇总
服务	DWS	指标宽表、关联主题、质量摘要	云端MySQL/MariaDB ADS主题表及备用CSV
交付	ADS	导出、权限、字典、刷新说明	项目二可消费数据产品

6.1 数据流

数据流 原始NC/NPZ/ZIP-CSV → Python解析与轻量化 → DataX采集 → HDFS/ODS → Hive/DWD → Spark/DWS/ADS → ECS MySQL/MariaDB结果库 → FineBI抽取。ADS同时导出CSV，作为核验、交换和FineBI备用数据源。

7 技术架构与部署

7.1 暂定技术栈

层次	技术	职责	是否核心
解析	Python + netCDF4/NumPy	NC/NPZ/ZIP读取、转换和质量规则	是
存储	HDFS	原始层与处理层文件存储	是
数仓	Hive	分层表、元数据和SQL分析	是
计算	Spark/PySpark	清洗、聚合、重网格和关联	是
采集	DataX	将Python转换后的标准CSV批量采集至HDFS，输出采集统计和日志	是
发布	MySQL/MariaDB	在ECS上分别建立Hive元数据库与ADS结果数据库，将Spark结果写入ADS库	是
编排	Shell	顺序执行、参数、日志、失败停止	是
备用	HDFS命令/CSV	`hdfs dfs -put` 用于DataX故障备用；ADS CSV用于FineBI备用接入	否，备用项

7.2 运行环境

项目	暂定要求
云服务器	阿里云ECS，4核8GB，80GB最低/100GB推荐
部署形态	单节点伪分布式；HDFS副本数1
操作系统	Alibaba Cloud Linux 3或Ubuntu 22.04 LTS，最终统一一种
数据库	ECS自建MySQL或MariaDB； `hive_metastore` 保存Hive元数据， `ocean_insight_ads` 保存ADS主题数据
FineBI	部署于客户端计算机，通过JDBC连接云端ADS库并采用抽取模式
网络	SSH仅限运维访问；数据库端口仅允许受控来源IP，使用FineBI只读账户

暂定配置 4核8G仅用于轻量化运行方案，不承诺直接处理21GB全量原始数据。配置需在同规格服务器完成性能基准测试后转为“已验证”。

8 功能需求

编号	需求名称	需求说明	优先级
FR-DP-001	环境自检	提供脚本检查JDK、Python、DataX、HDFS、Hive、Spark、MySQL/MariaDB、SSH、端口和可用磁盘。	P0
FR-DP-002	数据资产登记	记录文件名、格式、大小、年份、月份、指标、校验状态和处理批次。	P0
FR-DP-003	NC元数据读取	读取维度、变量、单位、FillValue、坐标范围和深度层，不加载无关变量。	P0
FR-DP-004	NC批量解析	按月份和指标批量展开目标层，输出规范字段并支持断点续跑。	P0
FR-DP-005	NPZ结构解析	列出数组键、形状、类型、样本数和数值范围；预测数据独立处理。	P1
FR-DP-006	ZIP流式采集	不全量解压年度ZIP，直接流式读取选定日CSV并验证表头。	P0
FR-DP-007	DataX采集入湖	使用DataX将标准CSV采集至HDFS规划目录，记录读取、写入、失败行数、字节数、批次和日志；HDFS命令作为备用。	P0
FR-DP-008	哨兵值清洗	将盐度999、热含量约1e30及明确无效值转换为NULL并标记原因。	P0
FR-DP-009	物理范围校验	对温度、盐度、溶解氧、海流、深度、经纬度和时长执行规则校验。	P0
FR-DP-010	坐标统一	ODS保留原坐标；DWD统一WGS84和-180—180经度。	P0
FR-DP-011	时间统一	解析年月/日期，生成year、month、year_month、observation_date。	P0
FR-DP-012	深度标准化	保留实际depth_m并映射SURFACE/SHALLOW/MIDDLE/DEEP层。	P0
FR-DP-013	海流派生	由u/v计算流速和流向，保留原始分量。	P0
FR-DP-014	渔船主数据关联	按mmsi + year关联flag_gfw、vessel_class_gfw及GFW规格字段。	P0
FR-DP-015	统一网格	将海洋和渔船数据映射到暂定2°网格，保留源网格追溯字段。	P0

编号	需求名称	需求说明	优先级
FR-DP-016	数仓分层	创建ODS/DWD/DWS/ADS表及分区，DWD/DWS优先采用Parquet。	P0
FR-DP-017	主题汇总	生成海洋月度、渔船月度、船旗国、船型和环境—渔船关联主题。	P0
FR-DP-018	质量报告	输出输入/输出行数、空值率、异常值、丢弃量、唯一键和质量评分。	P0
FR-DP-019	Shell编排	一键执行采集、清洗、建表、汇总、发布；失败即停并保存日志。	P0
FR-DP-020	可重跑	同一批次重复执行不得产生重复数据，支持按步骤和日期重跑。	P0
FR-DP-021	ADS发布	使用Spark JDBC将主题结果写入ECS上的`ocean_insight_ads`，并导出规范CSV；附表结构、口径、行数、校验值和刷新说明。	P0
FR-DP-022	运维检查点	每阶段提供执行命令、预期结果、检查SQL和常见错误处理。	P0
FR-DP-023	发布一致性	校验Hive/Spark结果、云端ADS表和备用CSV的行数、业务键唯一性、空值率及关键指标汇总，形成发布对账记录。	P0
FR-DP-024	版本与血缘	输出数据记录源文件、处理批次、脚本版本、生成时间和规则版本，支持从ADS追溯至输入文件。	P0

9 数据标准与数仓模型

9.1 统一数据标准

类别	标准
时间	UTC；日期yyyy-MM-dd；月份yyyy-MM；保留year/month字段
坐标	WGS84/EPSG:4326；纬度-90—90；经度-180—180
跨源网格	暂定2°×2°；grid_id由规范化网格左下角或中心点生成
深度	保留depth_m；映射SURFACE约1m、SHALLOW约100m、MIDDLE约500m、DEEP约1000m
温度	temperature_c，℃
盐度	salinity_g_kg，g/kg
溶解氧	oxygen_umol_kg，μmol/kg；不直接套用mg/L阈值
海流	current_u_ms/current_v_ms/current_speed_ms/current_direction_deg
热含量	ocean_heat_content_j_m2，J/m²；保留积分深度

类别	标准
缺失	DWD统一NULL，并用quality_flag标记MISSING/OUT_OF_RANGE/LAND_GRID/SOURCE_ERROR
命名	服务器路径、表名和字段使用小写英文snake_case，不使用中文和空格

9.2 关键业务键

对象	建议业务键
海洋格点明细	year_month + grid_id + depth_m + indicator_code
渔船日网格明细	observation_date + source_grid_id + mmsi
渔船主数据	mmsi + year
月度跨源主题	year_month + grid_id + depth_level

9.3 数仓表清单

层	代表表	说明
ODS	ods_ocean_nc_meta / ods_vessel_daily	保留源字段和批次信息
DWD	dwd_ocean_observation / dwd_vessel_activity	清洗、标准化、统一键
DWS	dws_ocean_monthly_grid / dws_vessel_monthly_grid	月度网格与分类汇总
ADS	ads_ocean_trend / ads_ocean_vessel_relation	面向FineBI的主题结果

10 轻量化数据方案

> 原则 轻量化采用区域、时间、网格和深度的结构化裁剪，不使用简单随机行抽样；必须保持跨年、季节、区域空间和主要类别的代表性。

10.1 提出轻量化方案的依据

轻量化不是因为数据“不重要”，而是为了在4核8G教学服务器上完整复现采集、转换、清洗、数仓分层、Spark聚合和发布流程。原始资产中，645个NC约13.966GB；渔船逐日数据解压后约23.24GB、共591,806,949条。若全部转换成二维CSV，体积还可能继续膨胀，既不适合多人教学，也不应直接交给FineBI。

五项海洋指标的时间覆盖并不一致：

指标	实际覆盖期	对轻量化选择的影响
温度、盐度、热含量	2016-01至2026-07，2026年不完整	可做较长单指标趋势，但不能与海流、溶解氧在2022年以后联合比较
海流、溶解氧	2011-01至2021-12	可做2011—2021单指标趋势，但2022年以后没有数据

指标	实际覆盖期	对轻量化选择的影响
五项指标共同期	2016-01至2021-12，共72个月	综合五指标时序和跨指标关联必须优先从该共同期选择
渔船逐日数据	2014—2024，共5.92亿条	与五指标共同分析时只能使用2016—2021的交集，且必须按时间和类别有结构地裁剪

因此，候选年份不能随意选。方案A、B、C都从五指标和渔船数据的共同范围中取样；区别是保留多少年、多少季节、多少深度和多少渔船明细。渔船数据也不能简单随机抽行，否则会破坏日期连续性，并可能让数量较少的船旗国、船型、作业类型或海域消失。

10.2 轻量化基准方案

本项目采用“西北太平洋五年期轻量化方案”，业务范围和数据范围保持一致：

数据	基准范围	裁剪与处理方式	目标规模
区域	10°N—50°N、120°E—160°E	保留西北太平洋典型渔场和明显海洋梯度	全部主题统一
时间	2017-01至2021-12，共60个月	位于五项海洋指标及渔船数据共同期内	五年连续
温度/盐度/溶解氧NC	区域内60个月	统一至2°×2°分析网格，保留海表及2—3个代表深度	每类约50—100MB
海流NC	区域内60个月	对u/v分量聚合后派生流速和流向，保留样本量	约50—120MB
热含量NC	区域内60个月	按源文件积分深度变量分别处理，不与普通深度混淆	约50—100MB
渔船逐日数据	2017—2021年区域内有效记录	ZIP流式读取；保留连续日期、全部有效船旗国和船型，不随机抽行	优先控制在300—500MB
渔船主表	入选活动涉及的 `mmsi + year`	保留船旗国、船型、主要规格和质量字段	约20—50MB
温度预测NPZ/CSV	结构检查及误差演示样本	因缺少真实日期、经纬度和深度，不做区域或渔船关联	约50—60MB
配置与校验	字典、清单、日志、校验值	与数据包一同交付	约20—50MB

目标运行包总量为0.8—1.2GB，单类数据原则上不超过500MB。该规模是基准目标，不是未经实测的精确承诺。

渔船数据若超过目标，按以下顺序缩减：先比较月份完整裁剪和连续日期裁剪，再减少代表深度；不得通过随机抽行或直接删除小船旗国、小船型来达标。所有裁剪必须生成前后分布对比和样本保留率。

10.3 项目二主题数据

项目二默认使用由最终确认的轻量化数据生成的ADS主题表，确保两个项目可以端到端复现。研发阶段可另行生成长周期聚合主题表，用于补充单指标长期趋势，但必须标明其来源范围、生成批次，且不得与教学轻量化结果混称。FineBI主查询表目标控制在100万行以内、100—300MB以内。

10.4 定版条件

1. 在4核8G/100GB同规格ECS完成Python转换、DataX采集、HDFS写入、Hive加载、Spark清洗和MySQL/MariaDB发布测试；
2. 比较裁剪前后年度、月份、船旗国、船型、作业类型和空间分布，确认代表性；
3. 若完整流水线超时或发生OOM，按既定顺序微调连续日期和代表深度，不破坏五年、四季和区域结构；
4. 基准测试通过后记录最终文件、行数、体积、耗时、内存和磁盘峰值，并将状态转为已验证。

11 非功能需求

编号	类别	要求	验证方式
NFR-DP-001	性能	单个教学步骤应尽快反馈进度；完整轻量化流水线目标20—30分钟，最终以基准测试定版	同规格ECS基准测试
NFR-DP-002	资源	运行不发生OOM，磁盘峰值不超过70GB	系统监控与df/free记录
NFR-DP-003	可靠性	失败步骤返回非零状态并保留可定位日志	故障注入
NFR-DP-004	幂等性	同批次重跑不产生重复业务键	重跑前后对账
NFR-DP-005	可维护性	参数、路径、日期和阈值配置化	代码审查
NFR-DP-006	安全	仅开放项目运行必要的SSH访问；不在脚本明文保存密码	端口与配置检查
NFR-DP-007	可审计	每个输出可追溯至源文件、批次和处理规则	抽样追溯
NFR-DP-008	文档性	技术文档包含部署、配置、命令、预期结果、检查点和排错说明	文档走查

12 交付物与验收

12.1 交付物

- 项目源代码：Python、PySpark、Hive SQL、Shell；
- 轻量化运行数据包及生成清单；

- ODS/DWD/DWS/ADS数据模型和建表脚本；
- 数据字典、指标口径、质量规则和处理日志说明；
- 部署手册、运行手册、测试报告和性能基准报告；
- ECS MySQL/MariaDB建库建表脚本、ADS主题表、备用CSV、数据字典及FineBI抽取说明。

12.2 验收矩阵

验收项	通过标准	证据
多源采集	NC、NPZ、ZIP/CSV均可识别并生成元数据	采集日志和样例输出
清洗	999、1e30、无效坐标/时间等按规则处理	质量前后对比
标准化	时间、经度、深度、单位和字段符合标准	DWD抽查SQL
数仓	四层表存在、分区合理、数据可追溯	Hive元数据和行数对账
计算	月度、网格、船旗国、船型、关联主题结果正确	抽样手算/SQL复核
流水线	Shell一键运行、失败停止、可重跑	完整运行记录
性能	4核8G轻量版不OOM，满足暂定时间和磁盘阈值	基准测试报告
数据交付	FineBI可通过受控只读账户连接云端ADS库并完成抽取，备用CSV结果一致	数据库连接、抽取日志和指标对账
# 13 风险与待确认事项		

编号	事项	当前处理	定版时点
R-01	4核8G性能尚未实测	暂定配置，构建后执行基准测试	详细设计/原型阶段
R-02	2°网格精度损失	保留源网格，比较1°/2°聚合	数据样例验证阶段
R-03	目标深度未必完全重合	选择最邻近真实层并记录actual_depth_m	转换规则定版
R-04	预测样例与脚本形状不一致	独立专题，先修正数据说明与输出协议	预测专题设计
R-05	操作系统尚未统一	Alibaba Cloud Linux 3与Ubuntu二选一	环境安装脚本前
R-06	轻量化实测规模可能偏离0.8—1.2GB	按缩减顺序微调连续日期和代表深度，并保留分布对比	基准测试阶段
R-07	FineBI远程连接受公网IP、安全组和数据库授权影响	限制来源IP、使用只读账户，并保留CSV备用接入	项目二原型阶段

14 附录

14.1 暂定目录规范

/oceaninsight/{raw,ods,dwd,dws,ads,logs,conf,scripts}；HDFS与本地目录使用同一层次语义。

14.2 参考资料

《海洋数据资产审计结论V1.0》；数据集随附说明文档。